DrBinati MedAssist

KI-gestützte multimodale medizinische Analyse

Präsentation | Cyprian Fusi

Nur zu Forschungs- und Bildungszwecken | Keine klinische Anwendung

Agenda

1. **Problemstellung & KI-Eignung** (2–3 Min.)
   - Geschäftsproblem, Nutzerwert und warum GenKI
   - Erfolgsmetriken und wesentliche Einschränkungen

2. **Daten & Modellansatz** (4–5 Min.)
   - Datenquellen, Verarbeitungspipeline und Modellwahl

3. **Systemarchitektur & Integration** (4–5 Min.)
   - Gesamtarchitektur und Komponentenintegration

4. **Wichtige Abwägungen & Entscheidungen** (3–4 Min.)
   - Technische Entscheidungen und geprüfte Alternativen

5. **Produktionsbetrieb & Verantwortungsvolle KI** (3–4 Min.)
   - Monitoring, Compliance und Weiterentwicklung

Die Herausforderung im Gesundheitswesen

Ärzte sind mit mehreren Datenquellen überlastet:

- EKG-Signale mit komplexen Wellenmustern
- Medizinische Bildgebung (Röntgen, CT, MRT)
- Unstrukturierte klinische Notizen mit kritischer Patientenhistorie

Aktuelle Probleme:

- Zeitaufwändige manuelle Korrelation der Datenmodalitäten
- Risiko, kritische Muster über Datentypen hinweg zu übersehen
- Facharztmangel in unterversorgten Regionen
- Kognitive Belastung bei hohem Patientenaufkommen

Benutzeroberfläche – Haupt-Dashboard

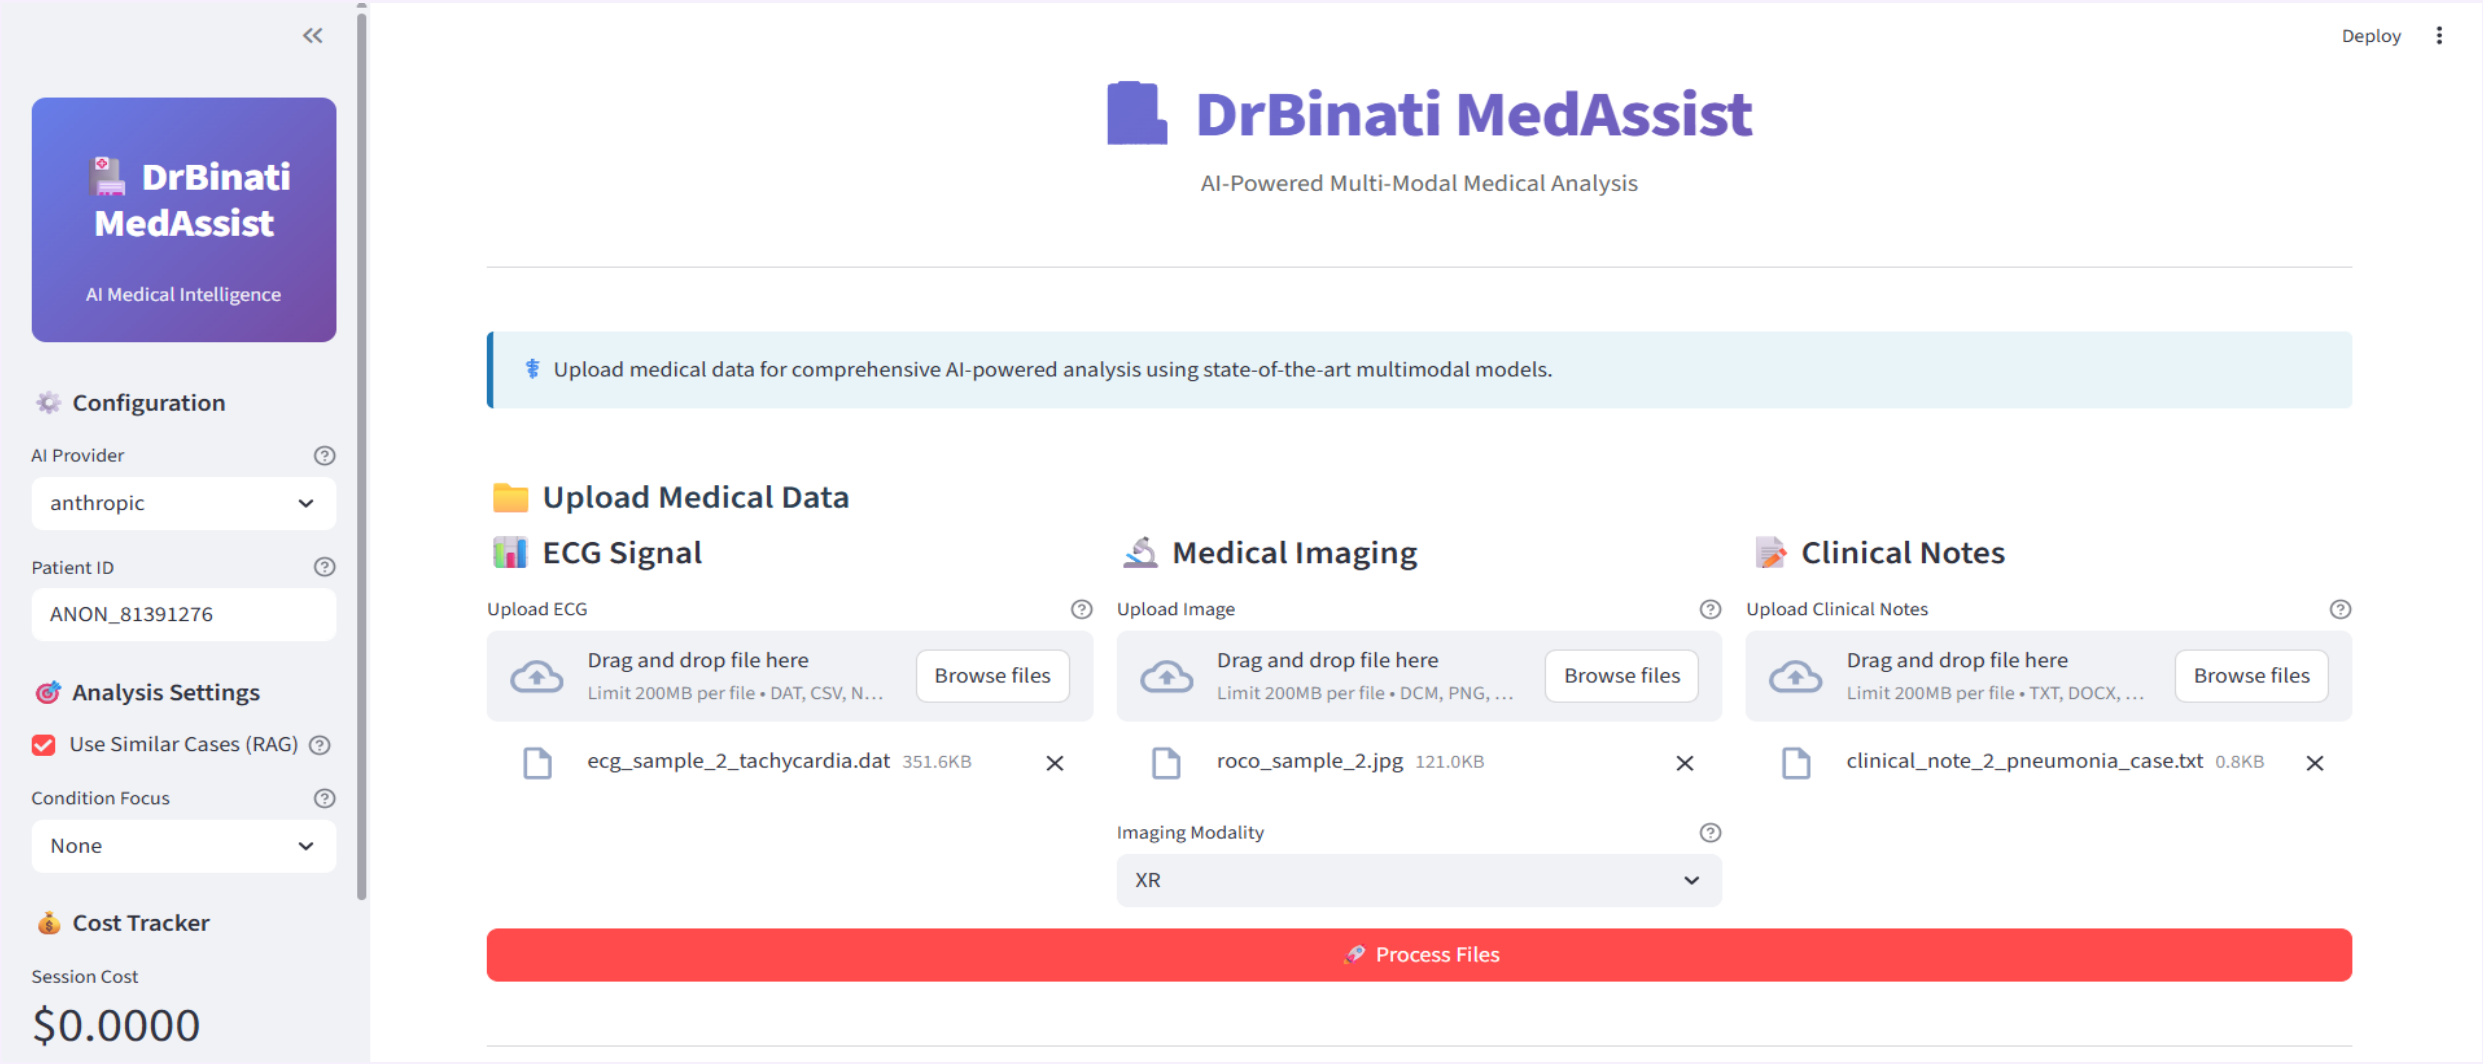


Abb. 1: Dreispaltige Upload-Oberfläche – EKG, Bildgebung und klinische Notizen

Warum Generative KI?

Vorteile von GenKI:

- Multimodales Verständnis:
  Bilder + Text + Signale gemeinsam

- Kontextuelles Denken:
  Befunde über Modalitäten korrelieren

- Natürlichsprachliche Ausgabe:
  Menschenlesbare Interpretationen

Warum NICHT nur Regeln?

- Medizinische Muster zu komplex
- Neuartige Befundkombinationen nötig
- Diverse unstrukturierte Daten

RAG-Erweiterung:

- Abruf ähnlicher historischer Fälle
  als Kontext für neue Analysen

- KI-Antworten in institutionellem
  Wissen verankern

- Vergleichende Diagnoseunterstützung

- Durchsuchbare Fallhistorie

Erfolgsmetriken:

- Analyse < 60 Sek. Latenz
- Kosten < $0,05 pro Analyse
- RAG-Abrufgenauigkeit > 80%

Daten & Modellansatz

Multimodale Datenquellen:

EKG-Signale:
- Formate: WFDB, CSV, NumPy
- Features: HF, HRV, R-Peaks

Medizinische Bildgebung:
- Formate: DICOM, NIfTI, PNG
- CLAHE-Enhancement + PHI-Anonymisierung

Klinische Notizen:
- De-Identifikation via Microsoft Presidio
- Max. 50.000 Zeichen pro Dokument

Modellwahl (Context Engineering):

Claude 3.5/3.7 Sonnet:
- Starke Vision-Fähigkeiten
- Exzellentes medizinisches Reasoning
- Kosteneffizient & stets aktuell (SOTA)

GPT-4o/Turbo (OpenAI):
- Alternative Provider-Option
- Vergleichbare Vision-Performance

RAG-System:
- PostgreSQL + pgvector
- BiomedNLP-PubMedBERT Embeddings
- 768/1536-dim. Vektoren

Datenvorschau – Medizinische Bildgebung (DICOM)

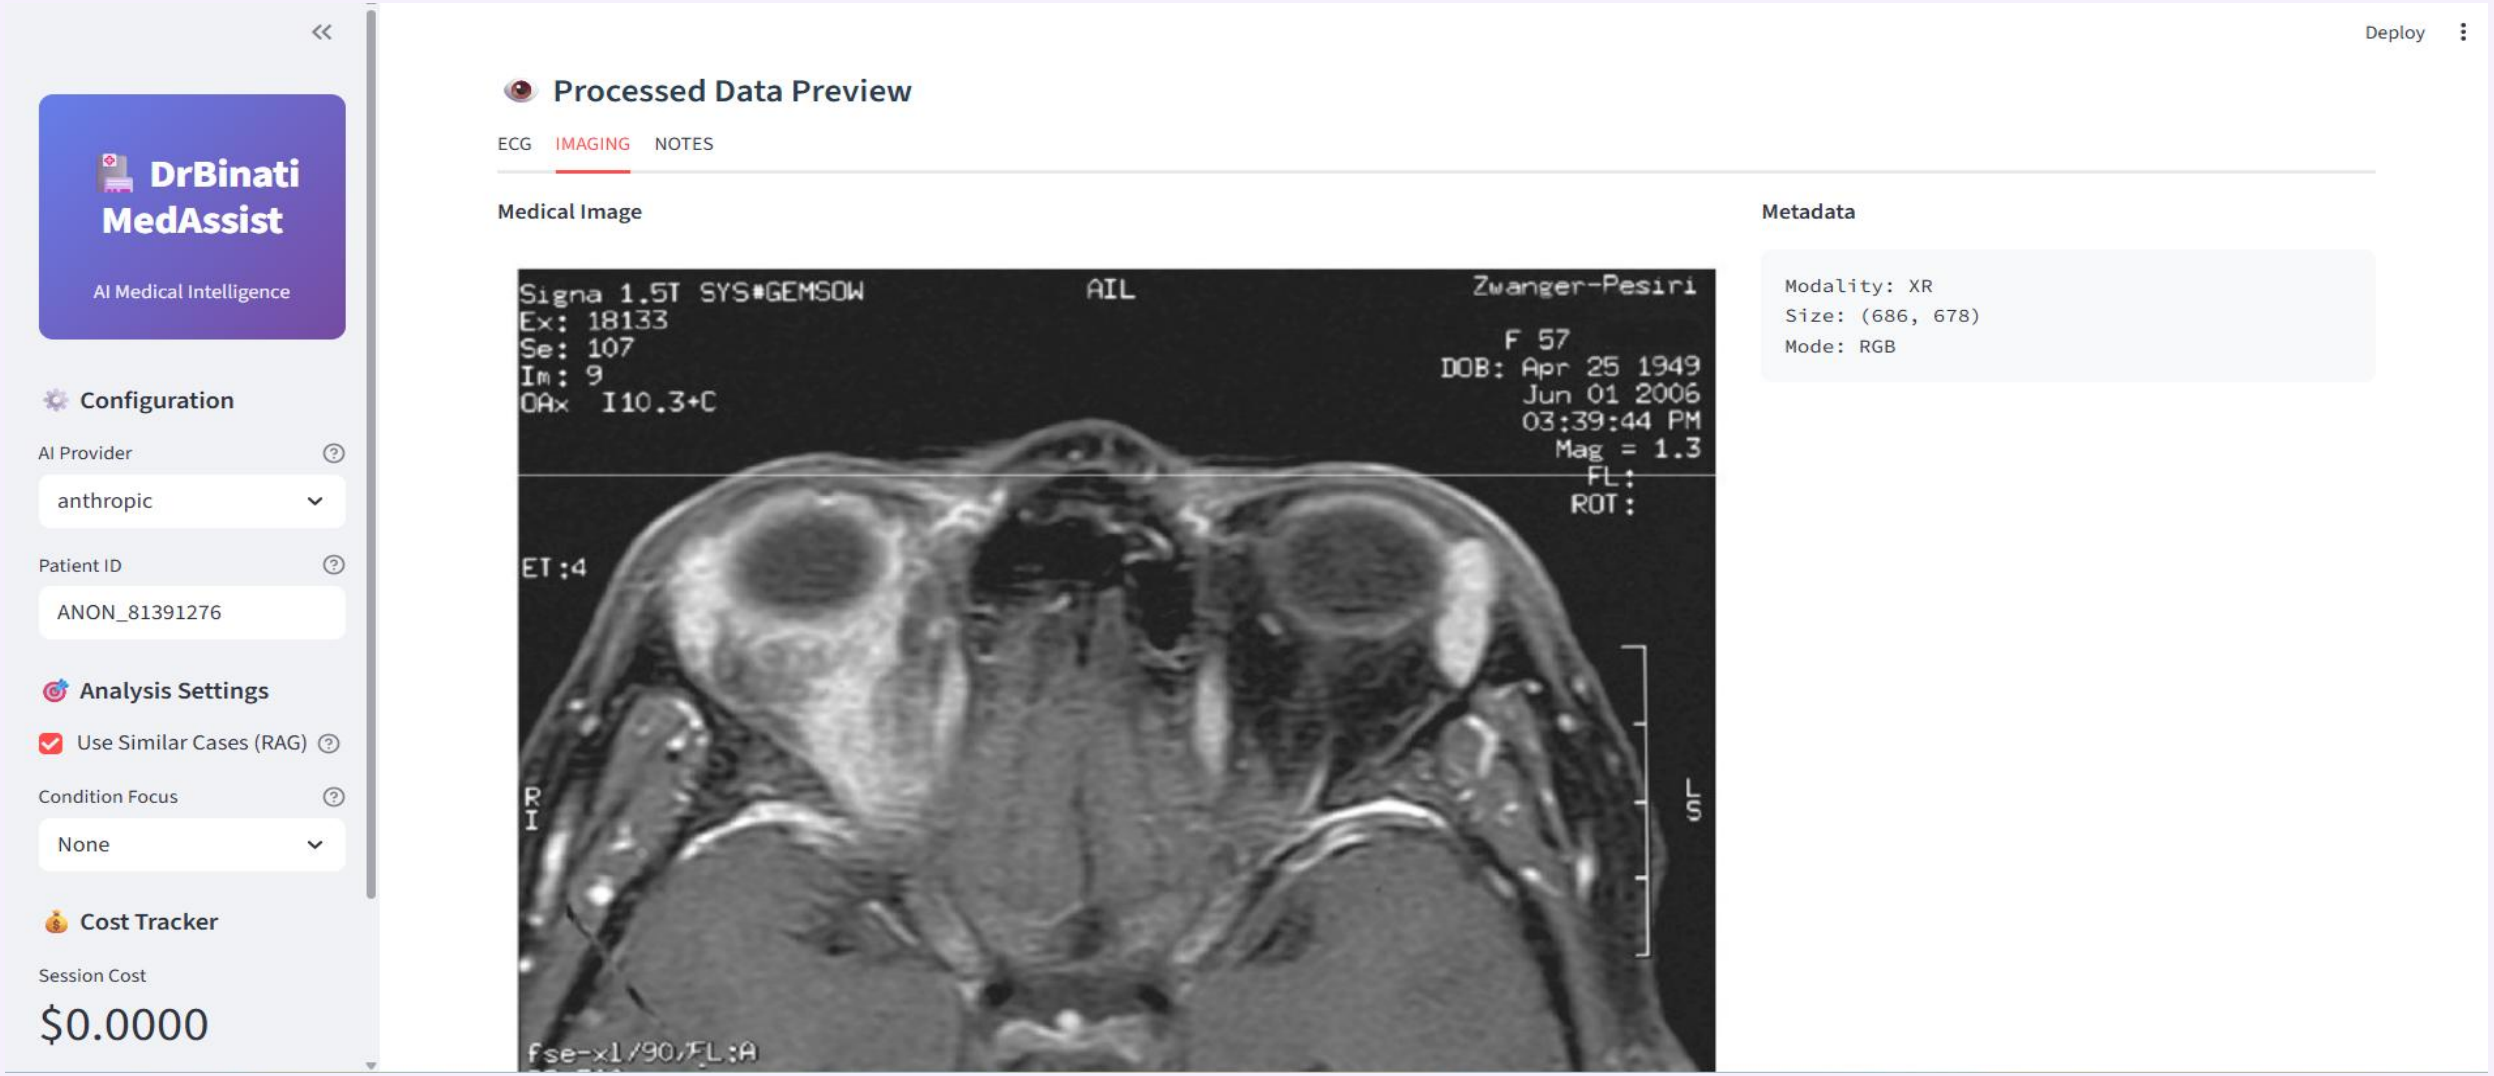
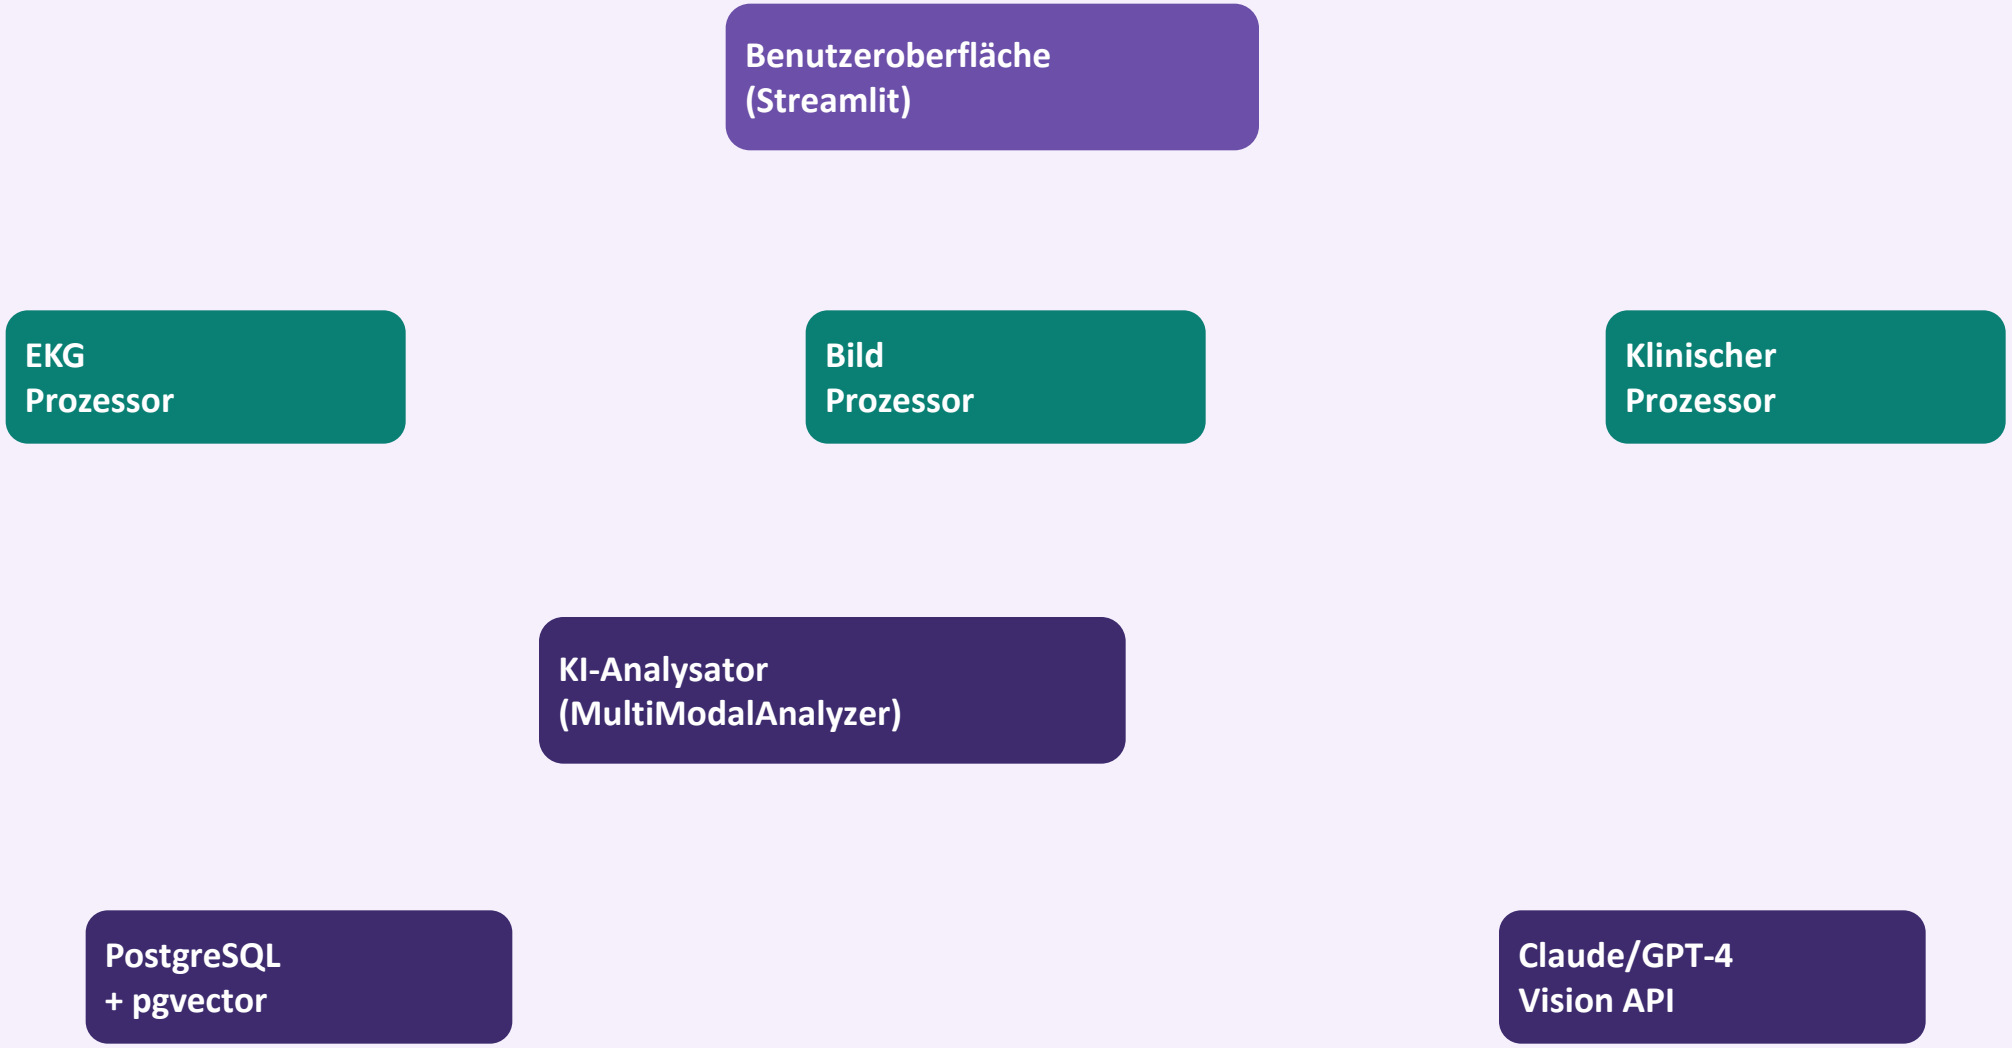


Abb. 2: DICOM-Bildvorschau mit automatisch extrahierten Metadaten (Modalität, Größe, Modus)

Systemarchitektur



Wichtige Abwägungen & Entscheidungen

Getroffene Entscheidungen:

API vs. selbst-gehostete Modelle:
→ Claude/GPT-4 APIs (kein A100-Zugang)

PostgreSQL vs. Vektordatenbank:
→ pgvector (einfacher, HIPAA-Pfad)

Streamlit vs. Custom Frontend:
→ Streamlit (MSc-Umfang)

Genauigkeit / Latenz / Kosten:
→ < 60 Sek., ~$0,04–0,05 pro Analyse
→ Tägliche Budget-Alarme bei 80%

Verworfene Alternativen:

Kein eigenes Modelltraining:
- PhysioNet: 10 TB Speicher nötig
- Daten nicht offen zugänglich
- Rechenkosten prohibitiv

Kein Fine-tuning (LLaVA/Med-PaLM):
- Erhebliche GPU-Ressourcen nötig
- Begrenzte medizin. Trainingsdaten
- Gefahr: 'Catastrophic Forgetting'
- Foundation-Modelle bereits exzellent

Kosten- & Latenz-Dashboard (Live-Tracking)

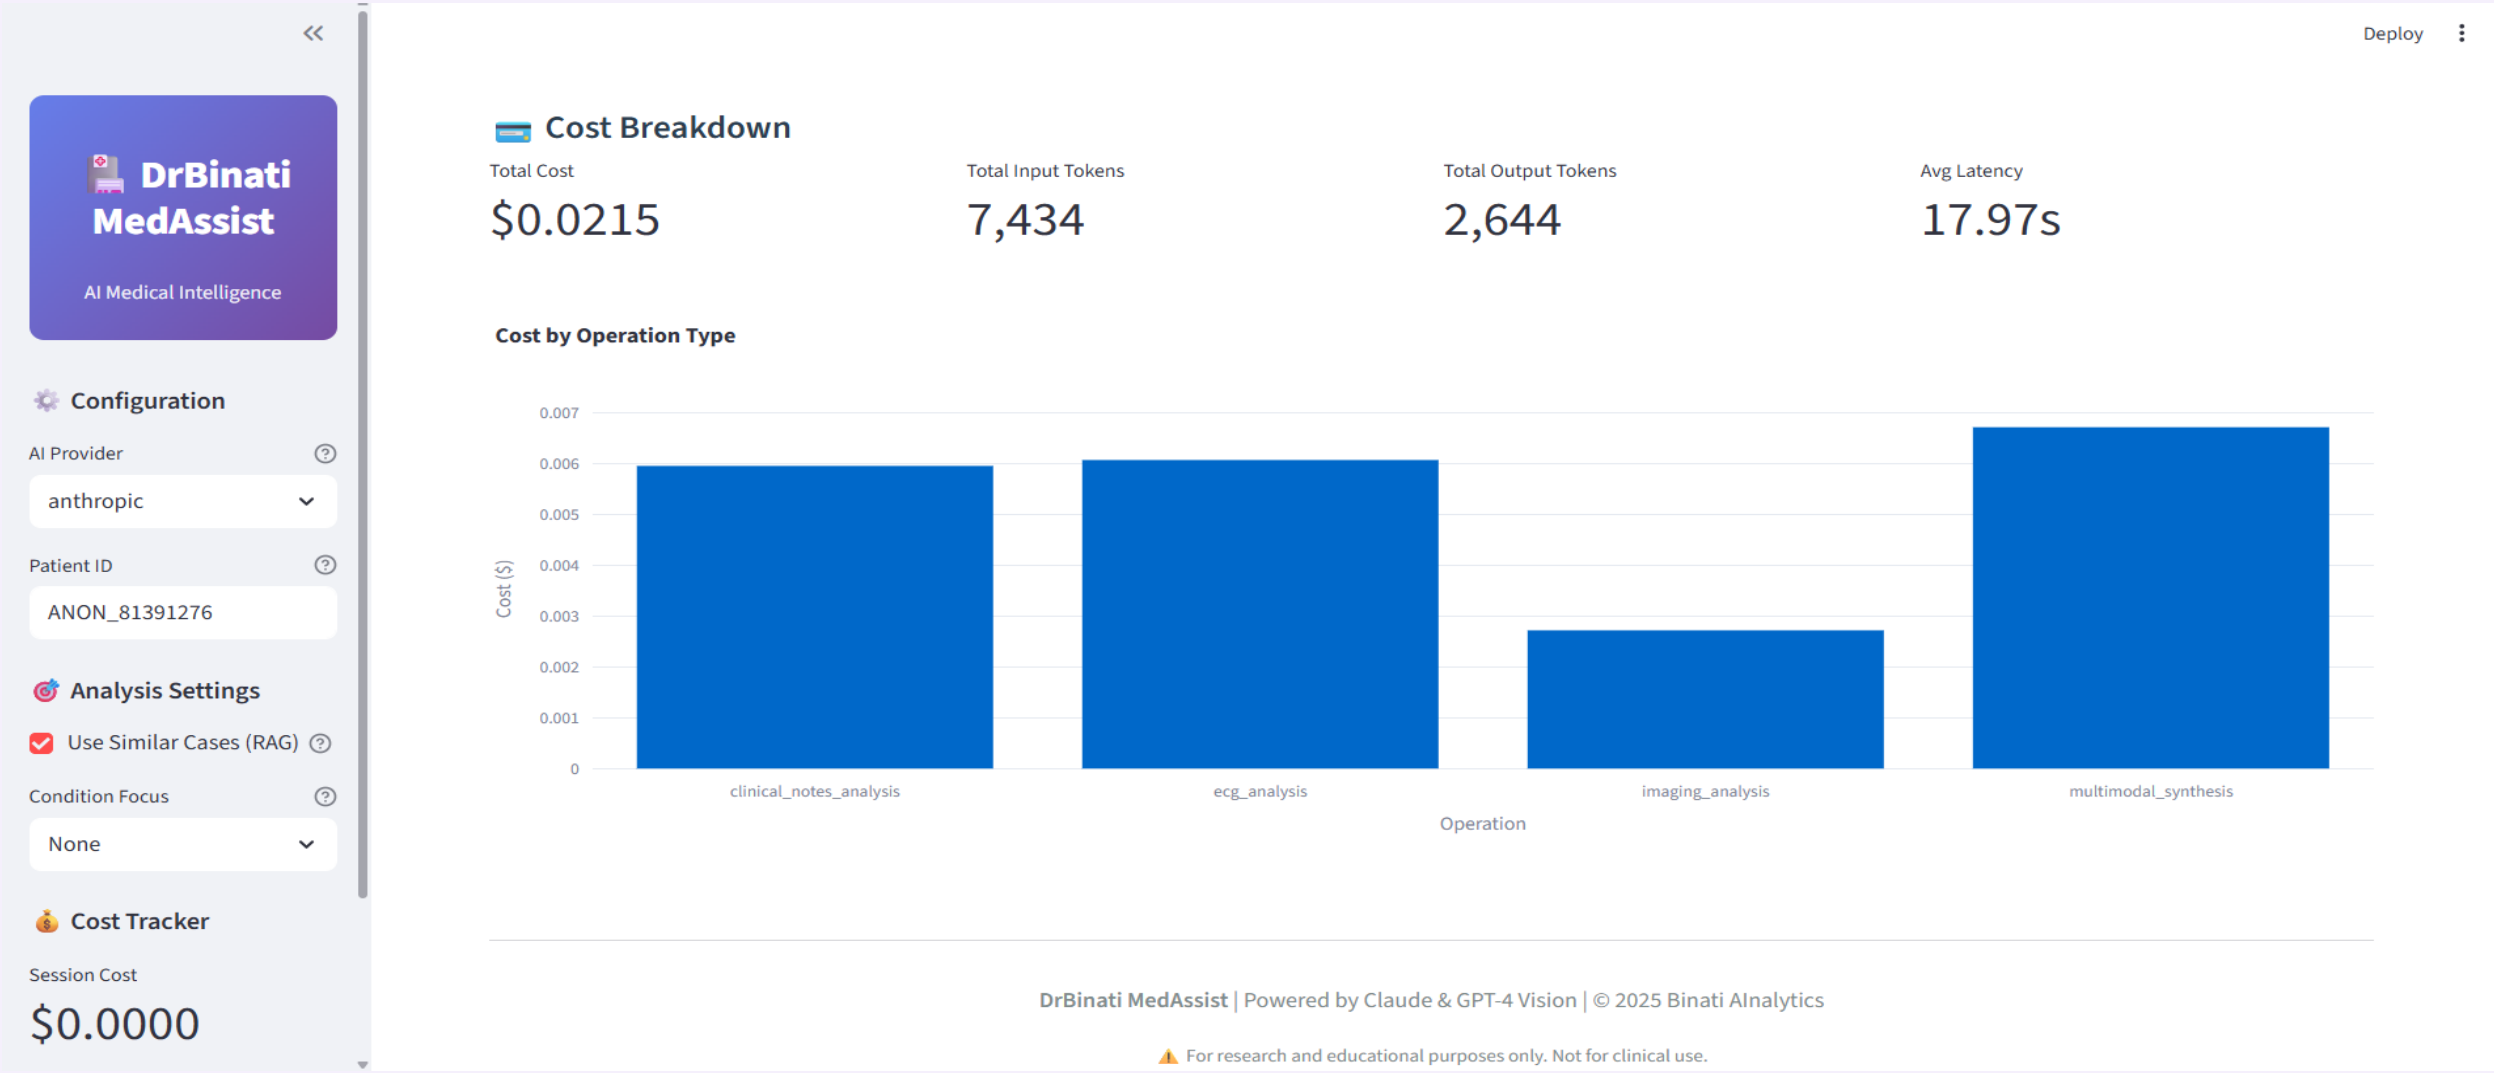


Abb. 3: Echtzeit-Kostenaufschlüsselung pro Operation – Gesamt $0,0215 bei 17,97 s Latenz

Produktionsbetrieb & Monitoring

Modell-Performance:

Laufzeit-Monitoring:
- Verarbeitungszeit pro Modalität
- Token-Nutzung & Kosten
- API-Fehlerraten

Qualitätsmetriken:
- Arzt-Feedback-Scores
- Vollständigkeitsprüfungen
- Halluzinationserkennung

Drift-Erkennung:
- Eingabedatenverteilungen überwachen
- Prompt-Verfeinerung bei Fehlern

Infrastruktur & Sicherheit:

Systemgesundheit:
- Datenbankverbindungspools
- API-Latenz-Tracking
- Budget-Alarme (80%-Schwelle)

HIPAA-Compliance:
- PHI-De-Identifikation
- Vollständiger Audit-Trail

Fehlerbehandlung:
- Graceful Fallback bei API-Ausfall
- Klare Fehlermeldungen
- Manuelle Review-Markierung

Analyseergebnis – Integrierte Multimodale Beurteilung

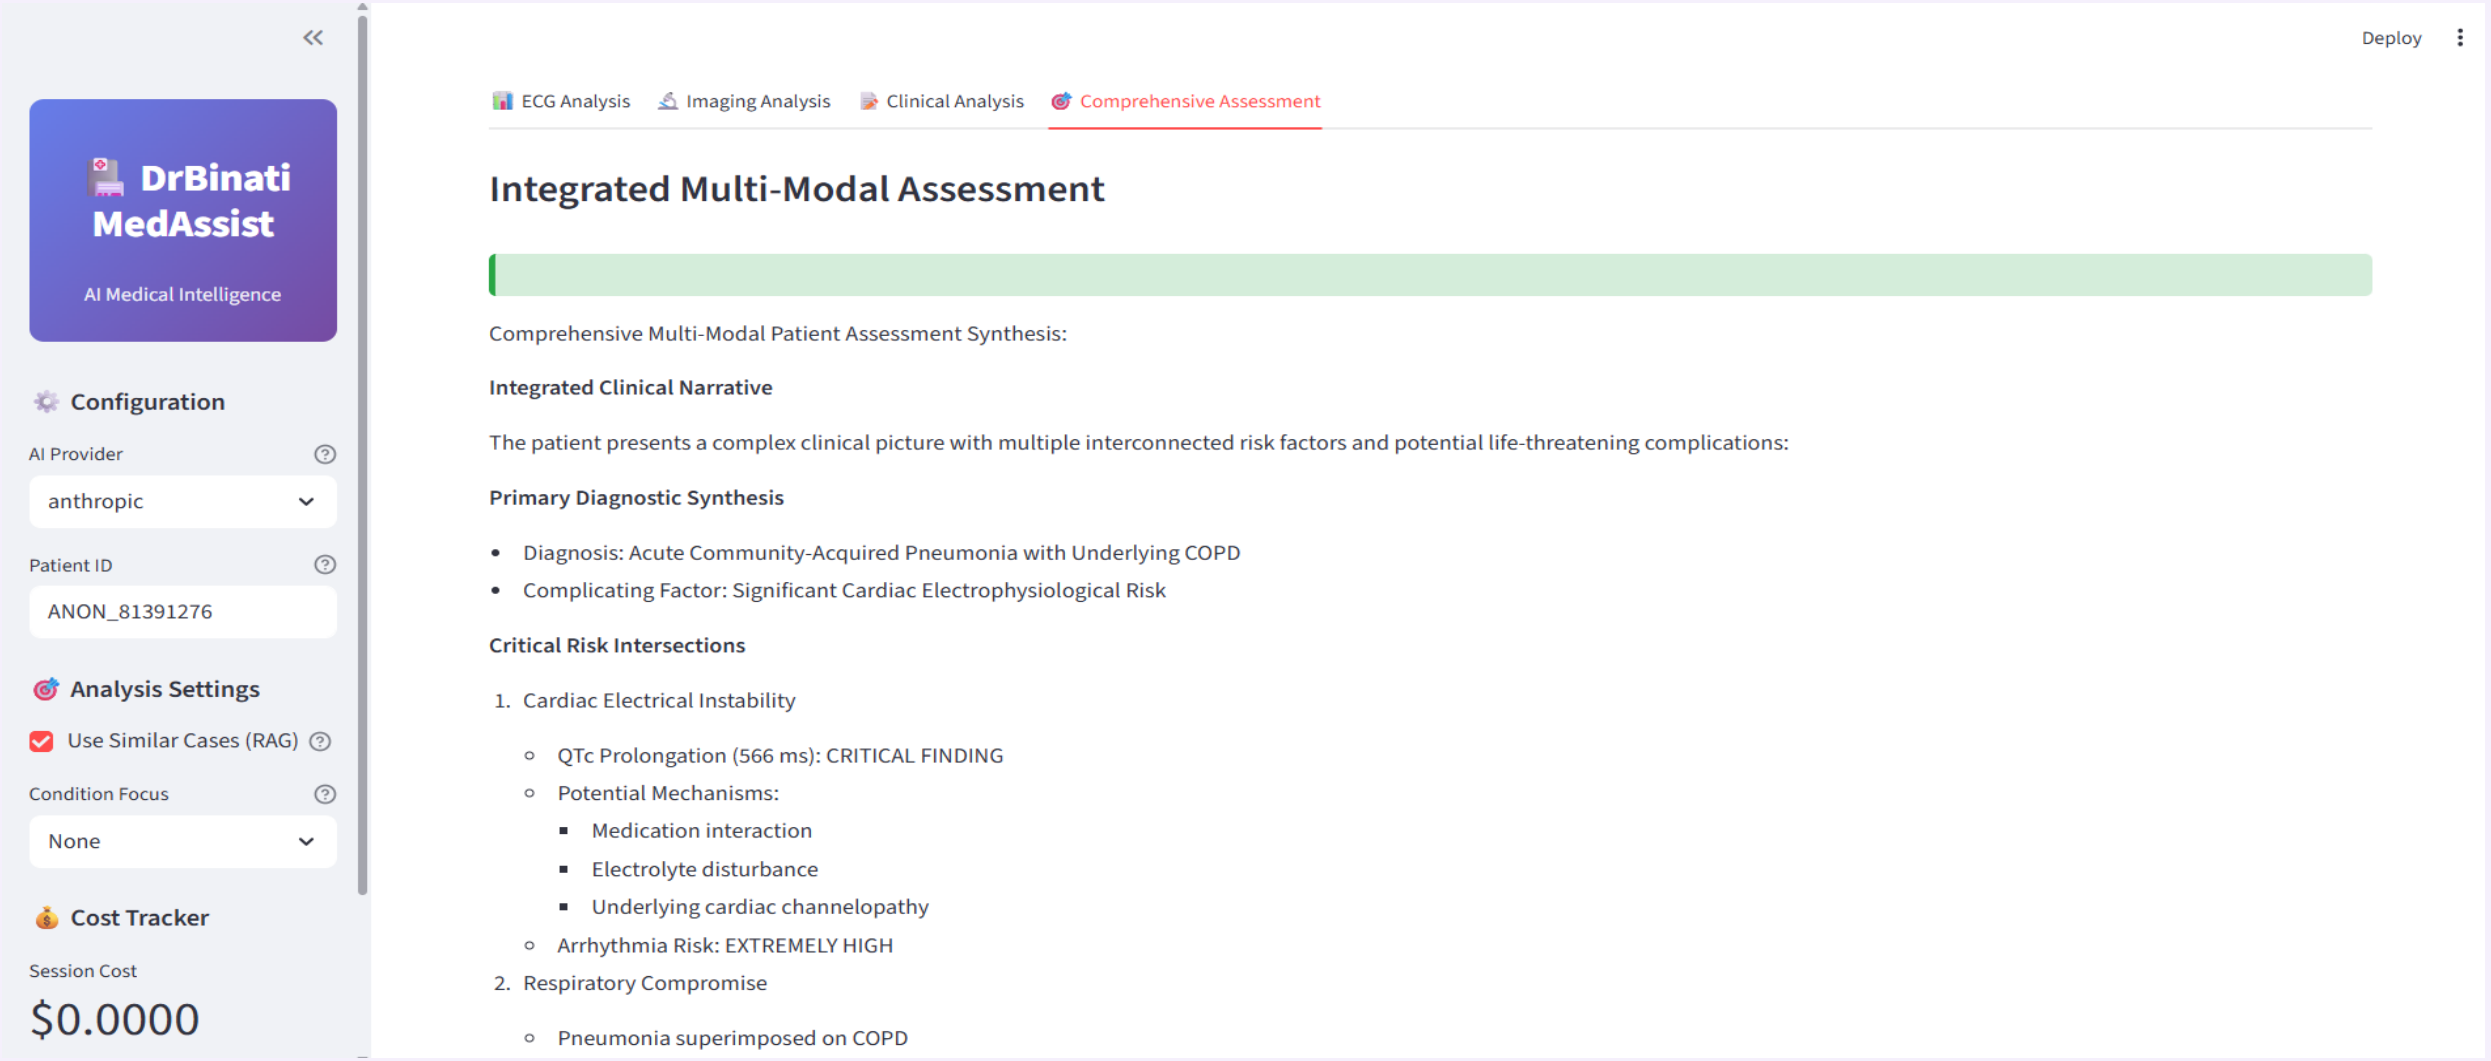


Abb. 4: KI-generierter Befundbericht – Diagnose Pneumonie + COPD mit kritischem QTc-Befund (566 ms)

Verantwortungsvolle KI & Weiterentwicklung

Verantwortungsvolle KI:

Bias-Minderung:
- Diverse Testfälle (Demografie)
- Regelmäßige Bias-Audits

Erklärbarkeit:
- Strukturierte Ausgabe mit Begründung
- Quellenzuschreibung in RAG
- Konfidenzindikatoren

Sicherheitsleitplanken:
- Kein klinischer Einsatz (Forschung)
- Ärztliche Aufsicht stets erforderlich
- PHI-Schutz auf jeder Ebene

Evolutionsstrategie:

Kurzfristig:
- Ultraschall, PET-Bildgebung
- Erweiterte Prompts
- Mobile-responsive UI

Mittelfristig:
- EHR-Integration (FHIR)
- Mehrsprachige Unterstützung
- Kollaborative Analyse

Langfristig:
- Klinische Validierungsstudien
- Regulatorischer Pfad (FDA/CE)
- Edge-Deployment (offline)

Wichtigste Erkenntnisse:

- Problem: Multimodale Medizindatenanalyse ist zeit- & ressourcenintensiv
- Lösung: KI-gestützte Synthese mit Claude/GPT-4 Vision
- Architektur: Modulares Design mit spezialisierten Prozessoren
- RAG-Erweiterung: Historische Fallsuche für besseren Kontext
- Abwägungen: Ausgewogene Genauigkeit, Latenz & Kosten
- Produktionsreif: Monitoring, HIPAA-Compliance, Evolutionspfad
- Verantwortungsvolle KI: Erklärbarkeit, Bias-Bewusstsein, Leitplanken

DrBinati MedAssist demonstriert das Potenzial von multimodaler GenKI in der medizinischen Entscheidungsunterstützung.

Fragen?